Анализ набора данных Iris и демонстрация переобучения

Салех Али — ИУ1И-41М

8 марта 2026 г.

1 Введение

Целью данной лабораторной работы является изучение базовых методов анализа данных и машинного обучения на примере набора данных **Iris**. В ходе работы были выполнены первичный анализ датасета, визуализация признаков с помощью **pairplot**, построение модели **логистической регрессии** для решения задачи бинарной классификации, а также демонстрация явления **переобучения** на примере **линейной регрессии** с полиномиальными признаками.

В работе использовался датасет Iris, содержащий измерения трёх видов ириса. Для бинарной классификации были выбраны два класса: **Iris-setosa** и **Iris-versicolor**. Дополнительно были сгенерированы искусственные данные для демонстрации того, как усложнение модели влияет на её способность к обобщению.

Ссылка на GitHub-репозиторий: `https://github.com/aliabokarim1992/lab1_SalehAli_01`

2 Обзор набора данных

Набор данных **Iris** является классическим учебным датасетом, опубликованным Рональдом Фишером в 1936 году [1]. Он содержит 150 наблюдений, относящихся к трём классам:

- **Iris-setosa**
- **Iris-versicolor**
- **Iris-virginica**

Каждый объект описывается четырьмя числовыми признаками:

- длина чашелистика (*sepal length*), см;
- ширина чашелистика (*sepal width*), см;
- длина лепестка (*petal length*), см;
- ширина лепестка (*petal width*), см.

Для решения задачи бинарной классификации в данной работе использовались только два класса — **Iris-setosa** и **Iris-versicolor**. Класс **Iris-virginica** был исключён, чтобы привести задачу к бинарному виду.

В таблице 1 приведены основные статистические характеристики исходного набора данных.

Таблица 1: Статистическое описание признаков набора данных Iris

Признак	**Минимум**	**Максимум**	**Среднее**	**Ст. отклонение**
Длина чашелистика, см	4.3	7.9	5.84	0.83
Ширина чашелистика, см	2.0	4.4	3.05	0.43
Длина лепестка, см	1.0	6.9	3.76	1.76
Ширина лепестка, см	0.1	2.5	1.20	0.76

Из таблицы видно, что признаки имеют разные диапазоны значений. Особенно хорошо различаются признаки, связанные с лепестками, что делает их важными для классификации видов ириса.

3 Визуализация данных

Для визуального анализа структуры данных был построен график **pairplot**, позволяющий одновременно исследовать распределения отдельных признаков и зависимости между ними.

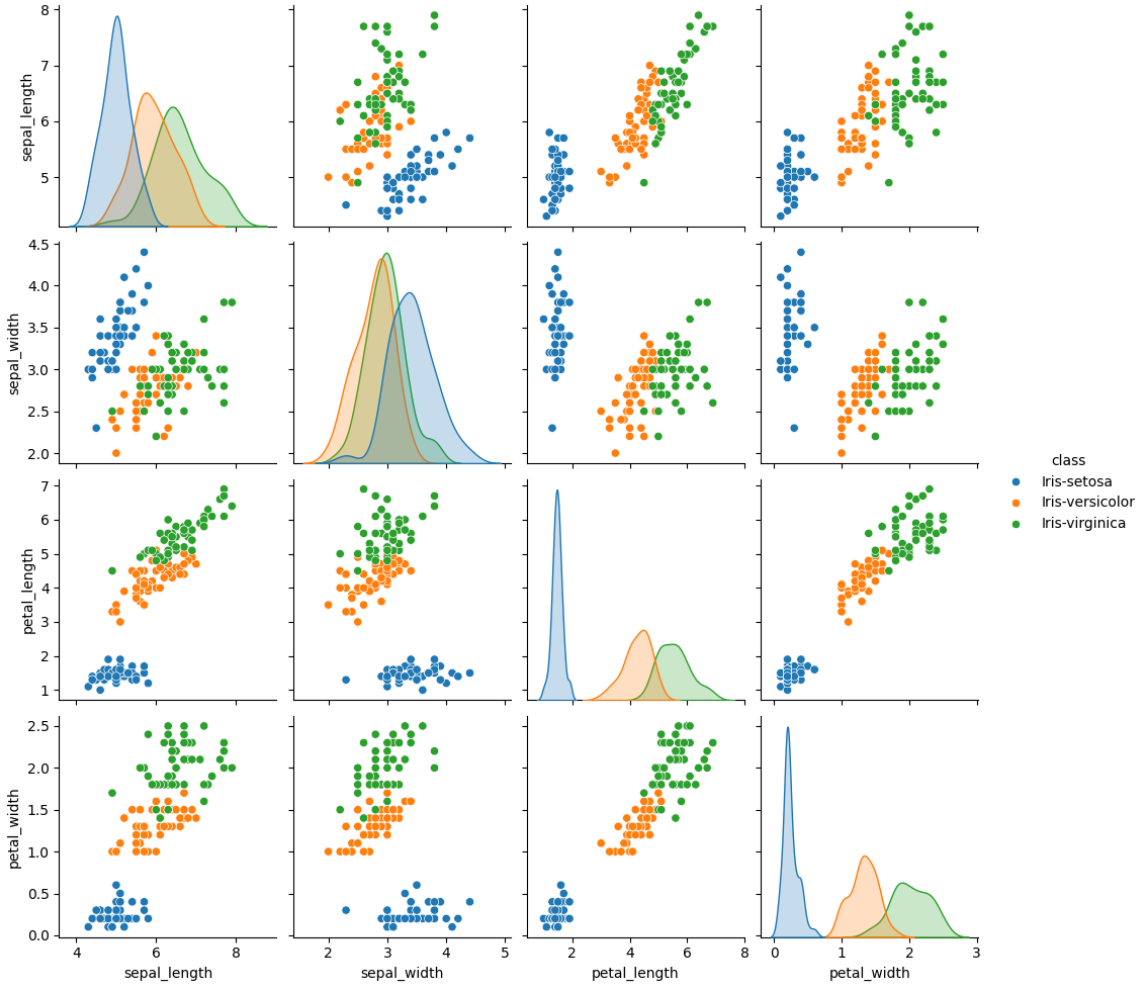

Рис. 1: Pairplot признаков набора данных Iris

Как видно на рисунке 1, класс **Iris-setosa** хорошо отделяется от остальных классов, особенно по признакам *petal length* и *petal width*. В то же время между классами **Iris-versicolor** и **Iris-virginica** наблюдается частичное пересечение. Это подтверждает, что задача разделения **Iris-setosa** и **Iris-versicolor** является корректной и хорошо подходит для демонстрации бинарной классификации.

Таким образом, визуализация данных позволяет заранее оценить степень разделимости классов и выбрать подходящий метод классификации.

4 Логистическая регрессия для бинарной классификации

4.1 Математическая модель

Логистическая регрессия используется для решения задач бинарной классификации и оценивает вероятность принадлежности объекта к одному из двух классов. Вероятность принадлежности к классу $y = 1$ задаётся выражением:

$$P(y = 1|X) = \sigma(W^T X + b) = \frac{1}{1 + e^{-(W^T X + b)}}, \tag{1}$$

где:

- X — вектор признаков;
- W — вектор весов модели;
- b — смещение;
- $\sigma(z)$ — сигмоидная функция.

Сигмоидная функция имеет вид:

$$\sigma(z) = \frac{1}{1 + e^{-z}}. \tag{2}$$

После вычисления вероятности объект относится к одному из двух классов на основе выбранного порога классификации.

4.2 Реализация модели

В процессе выполнения работы были выполнены следующие этапы:

- из исходного датасета были выбраны только классы **Iris-setosa** и **Iris-versicolor**;
- классы были закодированы числами 0 и 1;
- данные были разделены на обучающую выборку (80%) и тестовую выборку (20%);
- была обучена модель логистической регрессии;
- качество модели было оценено на тестовой выборке с помощью метрики accuracy и матрицы ошибок.

Для тестовой выборки было получено значение точности:

$$\text{Accuracy} = 1.0$$

Это означает, что модель правильно классифицировала все объекты тестовой выборки.

4.3 Матрица ошибок и анализ результата

Для более наглядной оценки качества модели была построена матрица ошибок, представленная на рисунке 2.

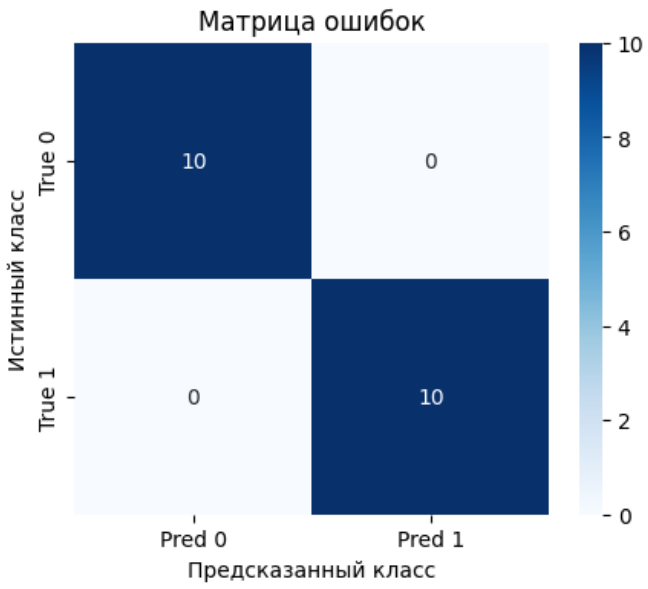

Рис. 2: Матрица ошибок для логистической регрессии

Согласно рисунку 2, модель правильно классифицировала все 10 объектов класса 0 и все 10 объектов класса 1. Ошибки классификации отсутствуют:

$$\begin{pmatrix} 10 & 0 \\ 0 & 10 \end{pmatrix}$$

Следовательно, логистическая регрессия показала **100% точность** на тестовой выборке. Такой результат объясняется хорошей разделимостью выбранных классов в пространстве признаков.

4.4 Теоретические замечания

Основная проблема переобучения заключается в том, что модель начинает запоминать обучающие данные, включая случайный шум, вместо того чтобы выявлять общие закономерности. В результате качество модели на обучающей выборке может быть высоким, а на новых данных — существенно хуже.

Именно поэтому нельзя оценивать качество модели только на тех данных, на которых она обучалась. Для корректной оценки необходимо использовать тестовую выборку, не участвующую в процессе обучения.

5 Демонстрация переобучения в линейной регрессии

5.1 Математическая модель

Линейная регрессия описывает зависимость между входными переменными и непрерывной выходной величиной:

$$y = W^T X + b + \varepsilon, \tag{3}$$

где ε обозначает случайный шум.

Для демонстрации переобучения были сгенерированы искусственные данные с нелинейной зависимостью и шумом. После этого были построены модели различной сложности с использованием полиномиальных признаков степеней 1, 4 и 15.

5.2 Искусственно сгенерированные данные

На рисунке 3 представлены искусственно сгенерированные данные, разделённые на обучающую и тестовую выборки.

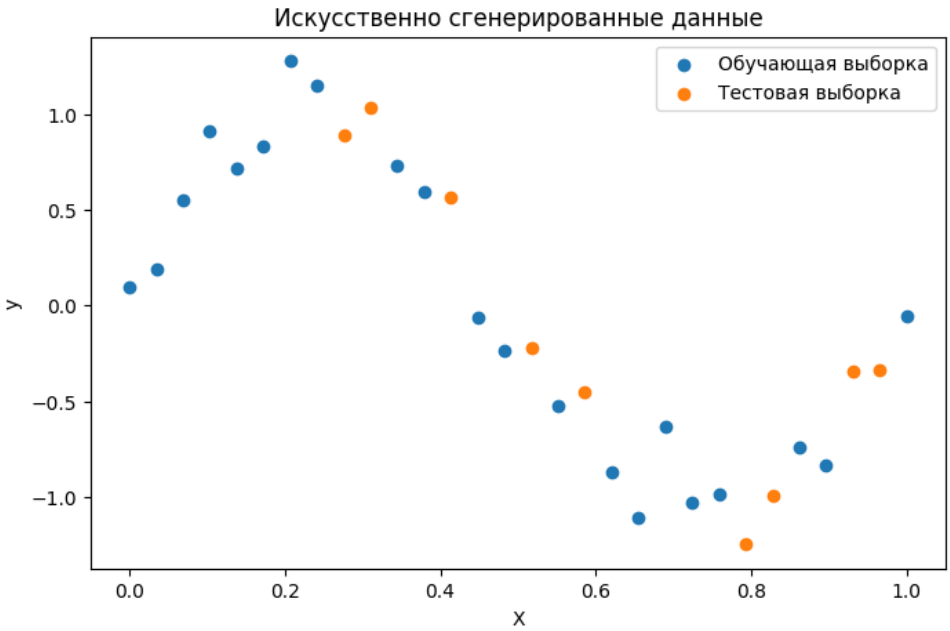

Рис. 3: Искусственно сгенерированные данные

Данные демонстрируют нелинейную структуру, поэтому они подходят для сравнения моделей различной сложности.

5.3 Модель степени 1

На рисунке 4 показан результат аппроксимации данных полиномом первой степени.

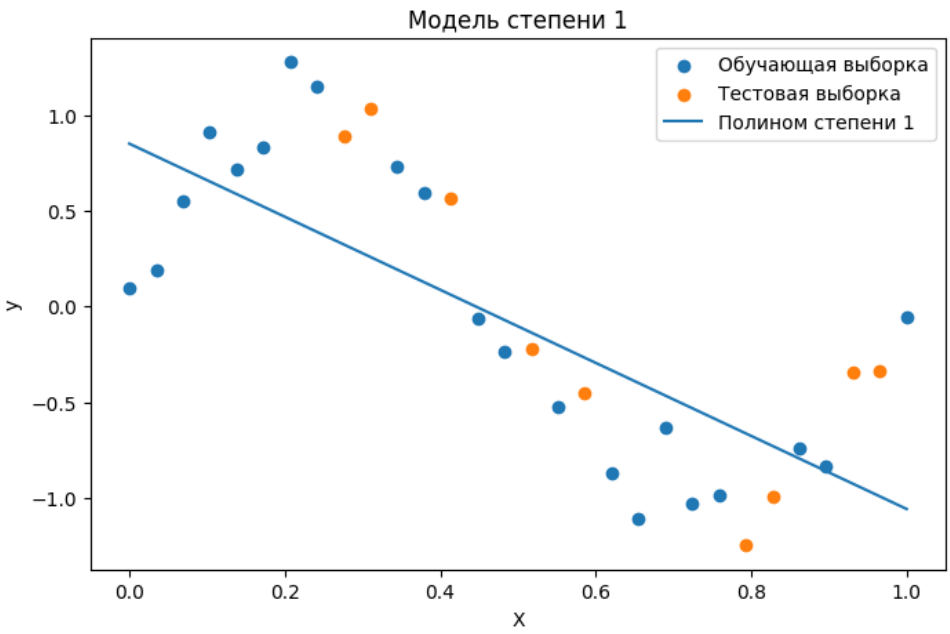

Рис. 4: Модель степени 1

Модель первой степени является слишком простой и не может адекватно описать нелинейную зависимость в данных. В данном случае наблюдается **недообучение**, поскольку модель не отражает общий характер распределения точек.

5.4 Модель степени 4

На рисунке 5 показана модель средней сложности — полином четвёртой степени.

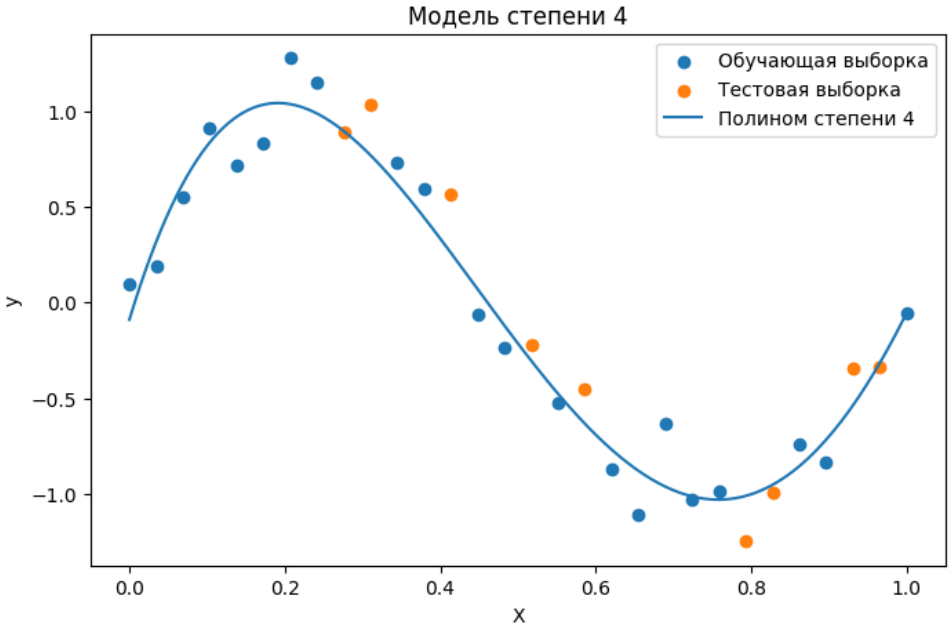

Рис. 5: Модель степени 4

В отличие от линейной модели, полином четвёртой степени хорошо описывает общую форму зависимости и не демонстрирует чрезмерных колебаний. Данная модель

обеспечивает разумный компромисс между простотой и точностью.

5.5 Модель степени 15 и переобучение

На рисунке 6 представлена модель полинома степени 15.

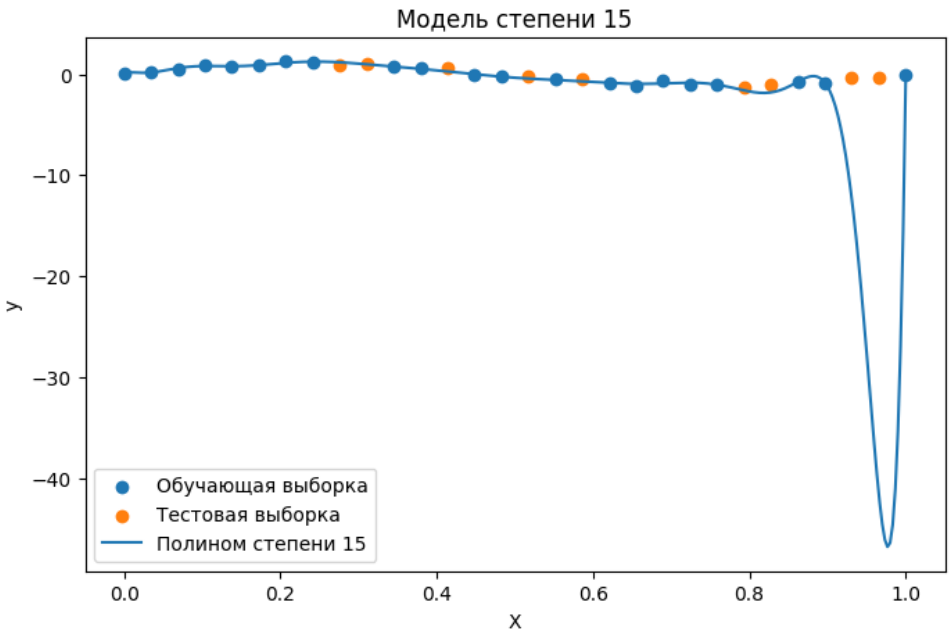

Рис. 6: Модель степени 15

Для полинома высокой степени наблюдается резкое усложнение формы кривой. В правой части графика кривая принимает неестественные значения и демонстрирует сильную нестабильность. Это означает, что модель слишком точно подстраивается под отдельные точки обучающей выборки и начинает учитывать шум как полезную закономерность.

Таким образом, модель степени 15 демонстрирует **явное переобучение**. Несмотря на хорошее согласование с обучающими данными, её способность к обобщению ухудшается.

5.6 Регуляризация как способ борьбы с переобучением

Одним из основных способов борьбы с переобучением является **регуляризация**. Суть регуляризации заключается в добавлении штрафа за слишком большие значения коэффициентов модели. Это позволяет ограничить сложность модели и сделать её более устойчивой к шуму.

Наиболее распространёнными видами регуляризации являются:

- **L1-регуляризация**, способствующая занулению части коэффициентов;
- **L2-регуляризация**, уменьшающая значения коэффициентов и сглаживающая модель.

Использование регуляризации особенно важно при работе со сложными моделями и большим числом признаков.

6 Заключение

В ходе лабораторной работы был исследован набор данных **Iris**, выполнен его первичный и визуальный анализ, а также решена задача бинарной классификации с помощью **логистической регрессии**. Полученные результаты показали, что выбранные классы **Iris-setosa** и **Iris-versicolor** хорошо разделяются в пространстве признаков, а модель обеспечивает **100% точность** на тестовой выборке.

Кроме того, на искусственно сгенерированных данных было показано, как изменение сложности модели влияет на качество аппроксимации и способность к обобщению. Полином первой степени продемонстрировал недообучение, полином четвёртой степени — наиболее адекватное приближение, а полином пятнадцатой степени — явное переобучение.

Основные выводы по работе:

- визуализация данных позволяет оценить разделимость классов ещё до обучения модели;
- логистическая регрессия является эффективным методом бинарной классификации;
- качество модели необходимо оценивать на тестовой выборке;
- чрезмерное усложнение модели приводит к переобучению;
- регуляризация является одним из основных способов уменьшения переобучения.

Список литературы

[1] R. A. Fisher, *The Use of Multiple Measurements in Taxonomic Problems*, Annals of Eugenics, 1936.

[2] T. Hastie, R. Tibshirani, J. Friedman, *The Elements of Statistical Learning*, Springer, 2009.

[3] C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006.