



Московский государственный технический университет
Факультет ИУ «Информатика и системы управления»
Кафедра ИУ-1 «Системы автоматического управления»

ОТЧЕТ

Лабораторная работа №1

по дисциплине

«Эргатические системы»

Выполнил: Мататов Р.И.

Группа: ИУ1-41М

Проверил: Кучин А.С.

Работа выполнена: 01/04/2026

Отчет сдан: 01/04/2026

Оценка:

Цель работы: Освоить базовые понятия машинного обучения, настроить пайплайн работы с git, научиться генерировать случайные выборки, визуализировать данные с помощью `pairplot`, строить модель логистической регрессии для бинарной классификации, а также продемонстрировать проблему переобучения модели линейной регрессии.

Ответы на вопросы:

1. В чем состоит основная проблема переобучения?

Основная проблема переобучения заключается в том, что модель слишком точно подстраивается под обучающие данные, включая случайный шум и выбросы, но при этом теряет способность к обобщению на новых, ранее не виденных данных. Признаки переобучения:

Модель показывает отличные результаты на обучающей выборке (точность близка к 100%)

Качество предсказаний на тестовой выборке значительно хуже

Модель "запоминает" данные, а не выделяет общие закономерности

2. Почему мы не можем оценивать качество модели на тех данных, на которых она обучалась?

Оценка качества на обучающей выборке дает смещенную (оптимистичную) оценку по следующим причинам:

Модель уже "видела" эти данные и могла адаптироваться к их особенностям и шумам

Существует риск переобучения, когда модель просто запоминает правильные ответы

Такая оценка не отражает реальную способность модели к обобщению

Невозможно определить, насколько хорошо модель справится с новыми данными

Именно поэтому в машинном обучении всегда используют разделение данных на обучающую и тестовую выборки.

3. Что такое регуляризация и как она помогает бороться со сложностью модели?

Регуляризация — это метод, добавляющий штраф за сложность модели к функции потерь. Основные типы:

L1-регуляризация (Lasso) — добавляет сумму абсолютных значений весов, приводит к разреженным решениям (обнуляет неважные признаки)

L2-регуляризация (Ridge) — добавляет сумму квадратов весов, уменьшает значения всех весов


Регуляризация помогает:

- Ограничивать величину параметров модели
- Уменьшать чувствительность к отдельным признакам
- Снижать дисперсию модели
- Находить баланс между сложностью модели и качеством обобщения
- Эффективно работать с многомерными данными

Результаты:

Визуальный анализ данных (pairplot) датасета Iris:

Pairplot Analysis of Iris Dataset



Наблюдается четкое разделение между видами ирисов по нескольким признакам

Вид *setosa* хорошо отделяется от двух других по длине и ширине чашелистиков

Виды *versicolor* и *virginica* частично пересекаются, что делает классификацию более сложной

Длина лепестка и ширина лепестка являются наиболее информативными признаками

Логистическая регрессия, классификация датасета Iris:

```

Распределение бинарных классов:
binary_target
0      100
1       50
Name: count, dtype: int64
Результаты бинарной классификации (Setosa vs Non-Setosa):
Точность на обучающей выборке: 1.0000
Точность на тестовой выборке: 1.0000

```


```


Classification Report на тестовой выборке:

```

	precision	recall	f1-score	support
Non-Setosa	1.00	1.00	1.00	30
Setosa	1.00	1.00	1.00	15
accuracy			1.00	45
macro avg	1.00	1.00	1.00	45
weighted avg	1.00	1.00	1.00	45

Обучение модели линейной регрессии с полиномиальными признаками разной степени (от 1 до 15). Распределение обучающих данных имеет вид функции синуса.





При увеличении сложности модели (степени полинома) ошибка на обучении увеличивается

Ошибка на тестовой выборке сначала уменьшается, достигая минимума а затем начинает расти

При степени 15 модель практически идеально подстраивается под обучающие данные, но показывает очень плохие результаты на тесте

Это классический пример переобучения: модель "запомнила" шум в обучающих данных и потеряла способность к обобщению

Вывод: В ходе работы выполнены все поставленные задачи. На датасете Iris построена модель логистической регрессии для бинарной классификации, достигнута 100% точность. На сгенерированных данных продемонстрировано переобучение: при увеличении сложности модели ошибка на обучении падает до нуля, а на тесте начинает расти, что подтверждает потерю способности модели к обобщению.