Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИУ «Информатика и системы управления»

КАФЕДРА ИУ-1 «Системы автоматического управления»

ОТЧЁТ
Задание №1

Дисциплина: 《Эргатические системы》

Студент Юй Вэньлун
фамилия, имя, отчество

Группа ИУ1И-41М

Преподаватель 01/04/2026 А.С. Кучин
(Подпись, дата) (И.О. Фамили

2026 2.

1. Цель работы

Освоить базовые понятия машинного обучения, настроить пайплайн работы с git, изучить генерацию случайной выборки и борьбу с переобучением.

2. Ответы на теоретические вопросы

Вопрос 1: В чём состоит основная проблема переобучения?

Ответ: Переобучение (overfitting) — это ситуация, когда модель слишком хорошо запоминает обучающие данные, включая шум и случайные колебания, вместо того чтобы выявлять общие закономерности. Основные проблемы:

- Модель становится слишком сложной и запоминает шум в данных
- Модель теряет способность обобщать знания на новые, не виденные данные
- Плохая предсказательная способность на новых данных

Вопрос 2: Почему мы не можем оценивать качество модели на тех данных, на которых она обучалась?

Ответ: Потому что модель уже видела эти данные в процессе обучения и могла их "запомнить". Оценка качества на обучающих данных даёт слишком оптимистичную оценку. Для реальной оценки необходимо использовать тестовые данные, которые модель не видела в процессе обучения.

Вопрос 3: Что такое регуляризация и как она помогает бороться со сложностью модели?

Ответ: Регуляризация — это техника добавления штрафа за сложность модели к функции потерь. Основные виды:

- **L1 регуляризация (Lasso)**: добавляет L1 норму вектора весов, что может обнулить некоторые веса (выбор признаков)
- **L2 регуляризация (Ridge)**: добавляет L2 норму вектора весов, приближая веса к нулю

Регуляризация ограничивает веса модели, не позволяя им становиться слишком большими, что уменьшает переобучение.

3. Результаты экспериментов

Задание 1: Загрузка и визуализация датасета Iris

Описание датасета:

- Источник: встроенный датасет Iris из библиотеки sklearn
- Количество образцов: 150
- Количество признаков: 4 (длина чашелистика, ширина чашелистика, длина лепестка, ширина лепестка)
- Количество классов: 3 (Setosa, Versicolor, Virginica)

Статистическое описание:

Признак	Среднее	Ст. отклонение	Мин	Макс
Длина чашелистика (см)	5.84	0.83	4.3	7.9
Ширина чашелистика (см)	3.05	0.44	2.0	4.4
Длина лепестка (см)	3.76	1.77	1.0	6.9
Ширина лепестка (см)	1.20	0.76	0.1	2.5

Анализ визуализации:
С помощью pairplot можно наблюдать:

- Три вида ирисов чётко разделяются в пространстве признаков
- Длина и ширина лепестка лучше всего разделяют классы
- Длина и ширина чашелистика имеют некоторое перекрытие между классами

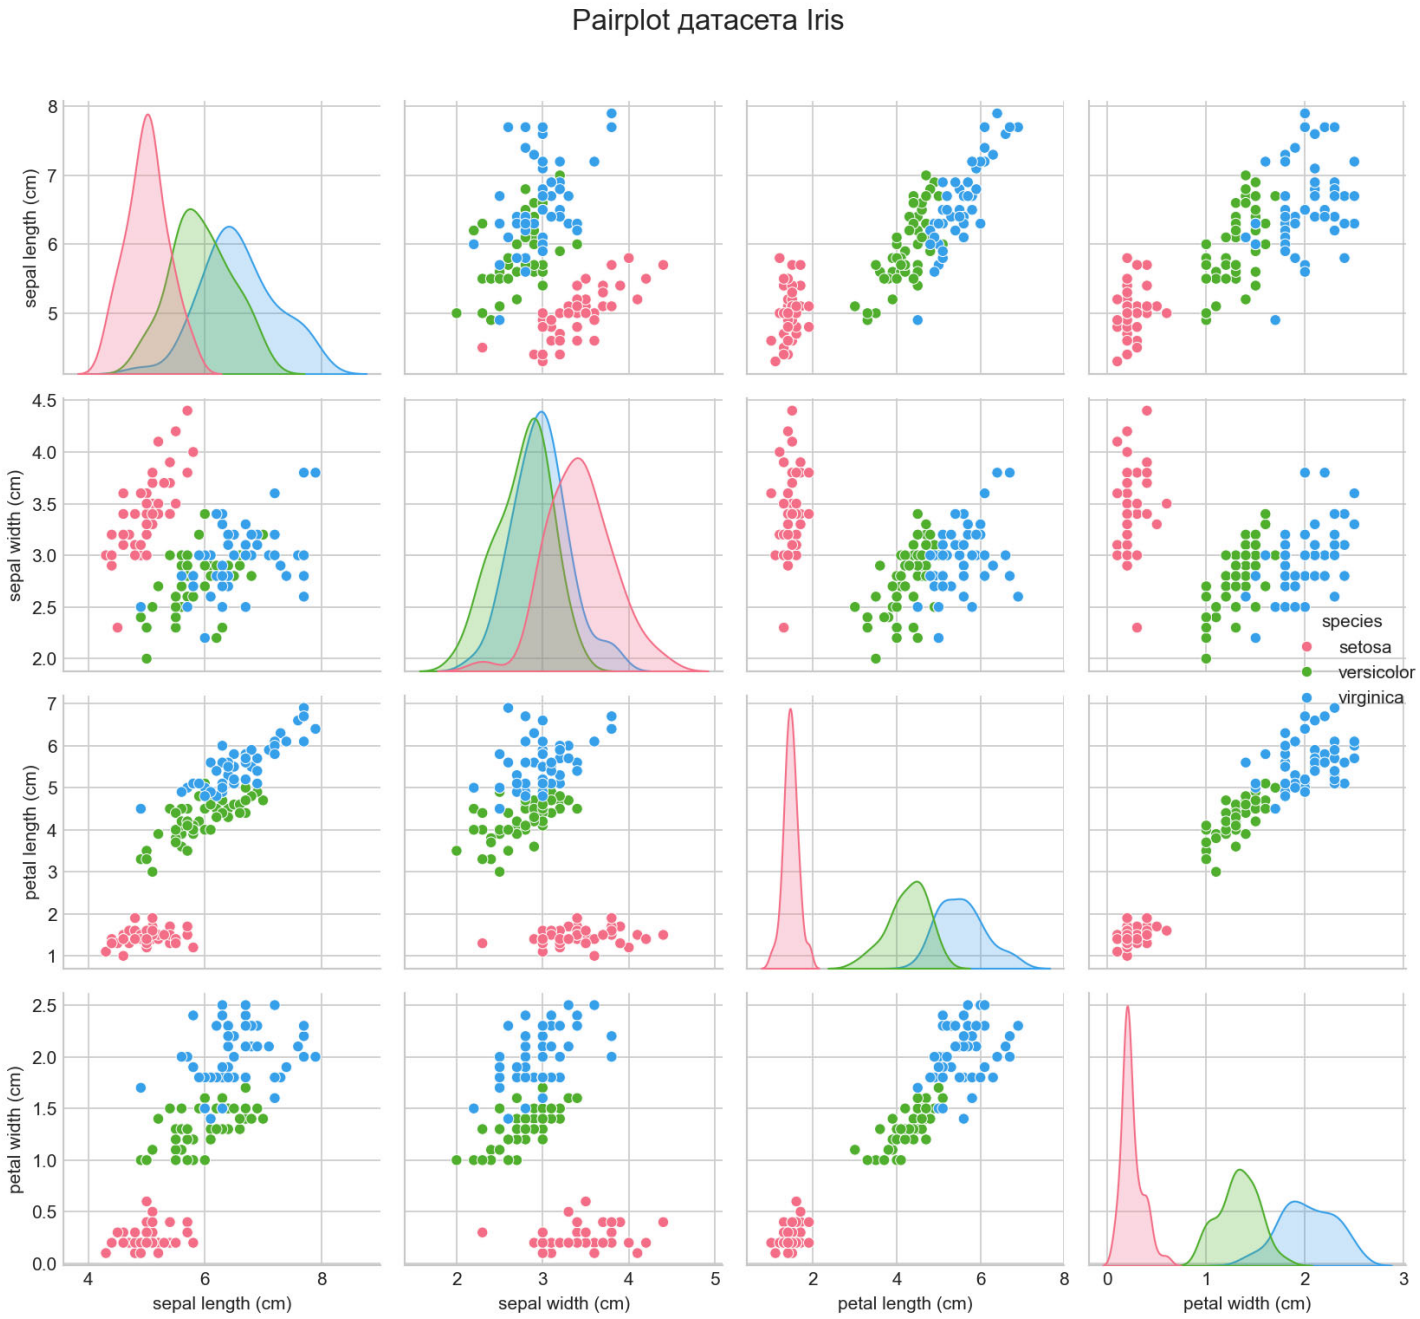

Задание 2: Логистическая регрессия для бинарной классификации

Экспериментальная установка:

- Классификация: Versicolor против Virginica
- Разделение данных: 70% обучение, 30% тест
- Случайное зерно: 42 (для воспроизводимости)

Производительность модели:

Метрика	Значение
Точность на обучающей выборке	95.71%

Метрика	Значение
Точность на тестовой выборке	93.33%

Отчёт по классификации:

Класс	Precision	Recall	F1-Score	Support
Versicolor	0.88	1.00	0.94	15
Virginica	1.00	0.87	0.93	15

Вывод: Малая разница в точности между обучающей и тестовой выборками (всего 2.38%) показывает, что модель обладает хорошей обобщающей способностью и не демонстрирует переобучения.

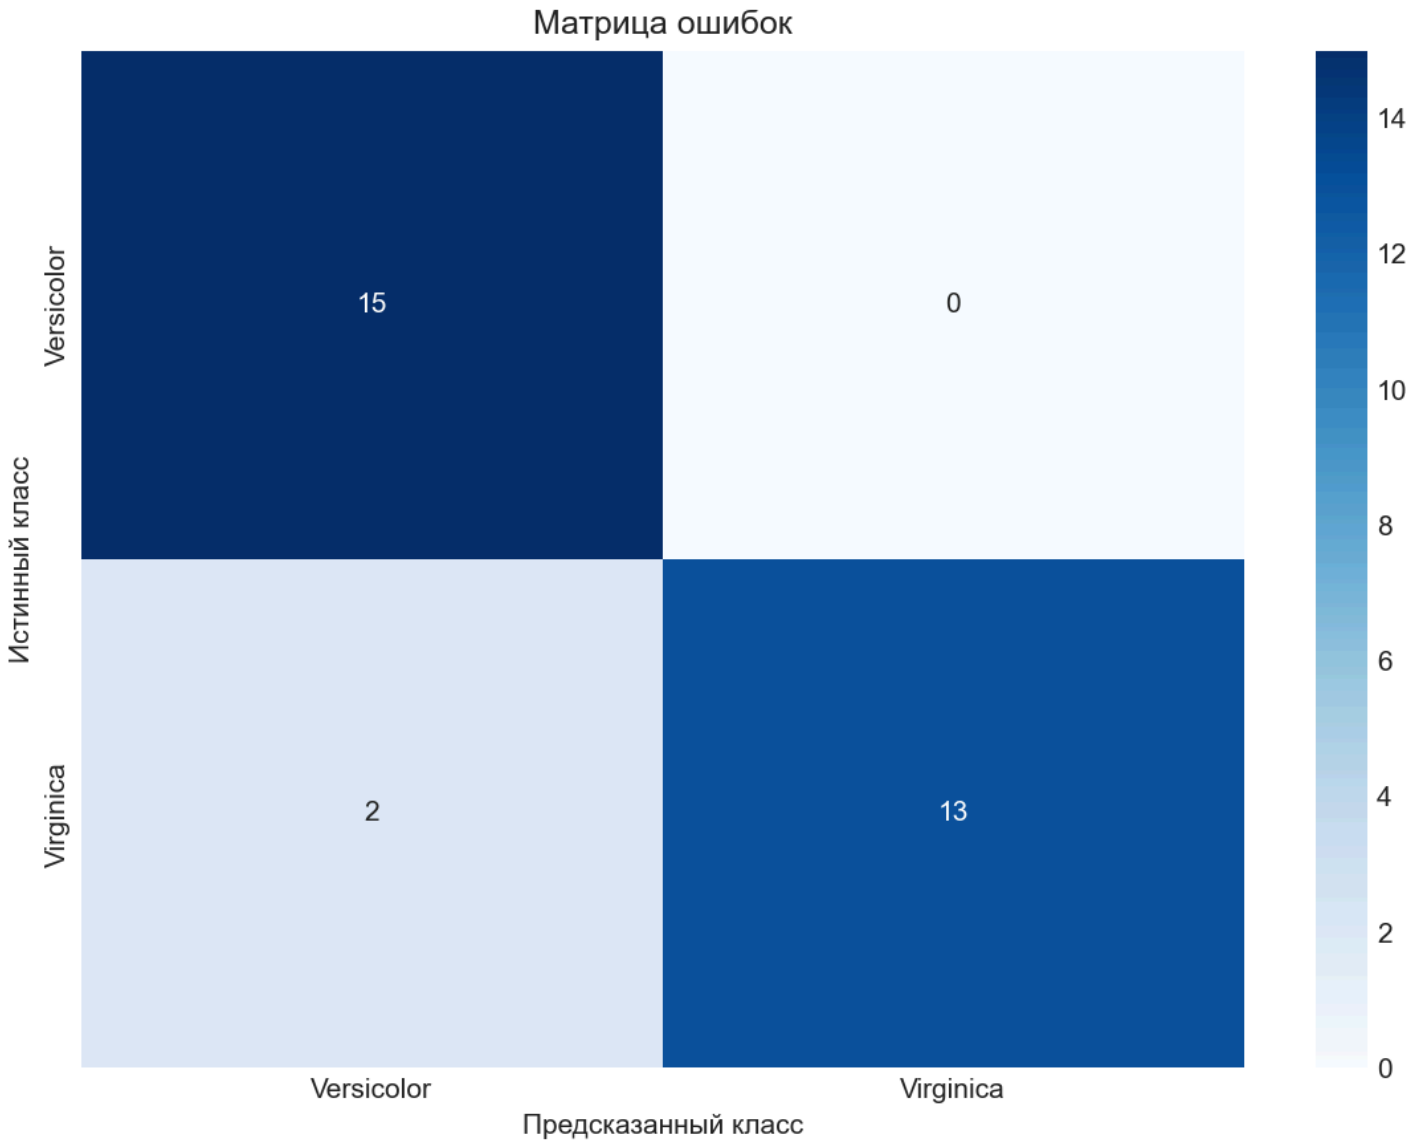

Рис: Матрица ошибок логистической регрессии на тестовой выборке

Задание 3: Демонстрация недообучения и переобучения

Экспериментальная установка:

- Истинная зависимость: $y = 0.3x^2 + 1$ (нелинейная)
- Добавленный шум: среднее 0, стандартное отклонение 3
- Количество образцов: 50
- Разделение обучение/тест: 70%/30%

Сравнение моделей:

Степень полинома	R^2 обучение	R^2 тест	Разница	Состояние
1	0.8194	0.7608	0.0587	Недообучение
3	0.8974	0.8516	0.0459	Хорошо
10	0.9170	0.8540	0.0630	Хорошо
15	0.9235	0.7211	0.2024	Переобучение

Анализ визуализации:

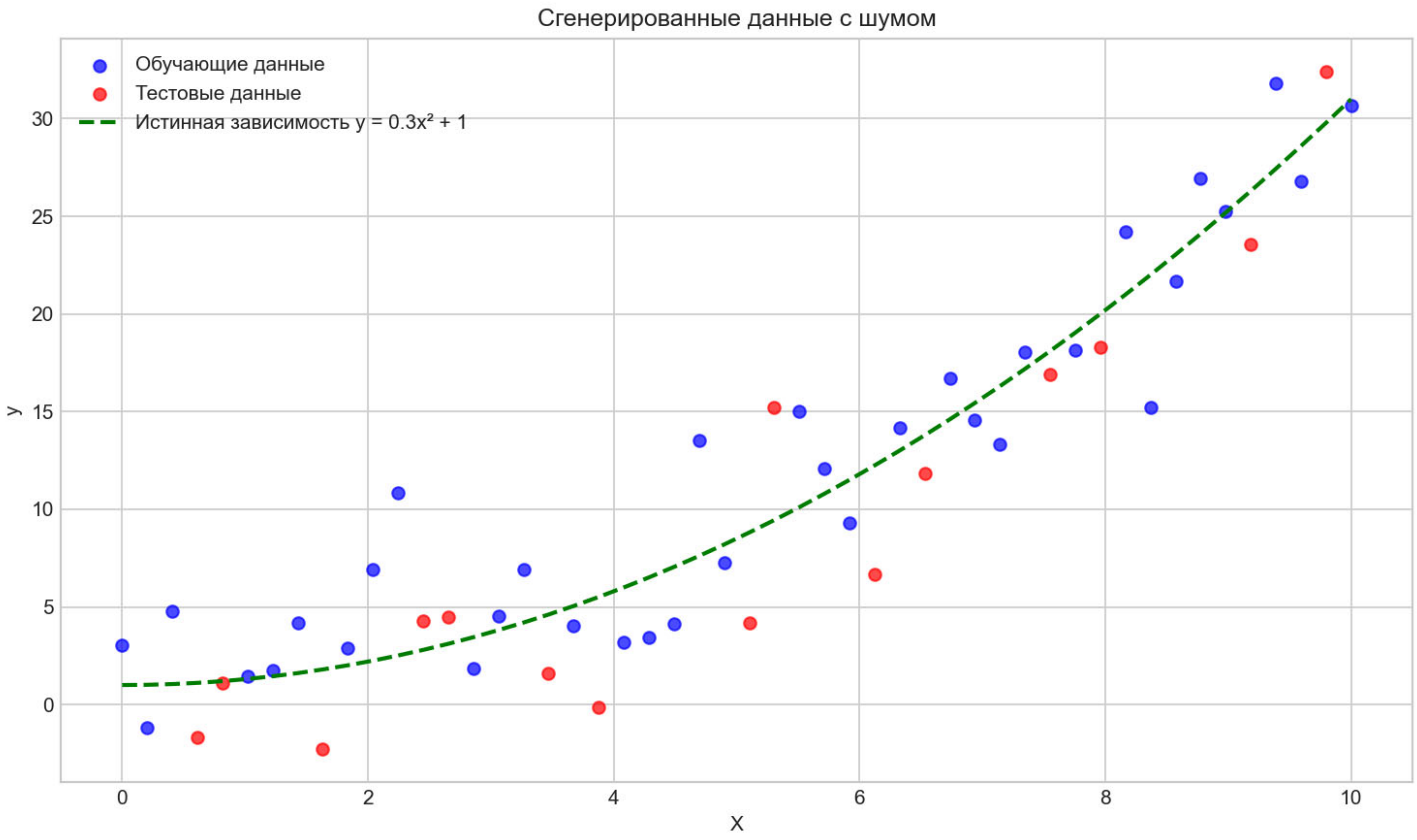

Рис: Сгенерированные синтетические данные (синий - обучающая выборка, красный - тестовая выборка, зелёная пунктирная линия - истинная зависимость $y=0.3x^2+1$)

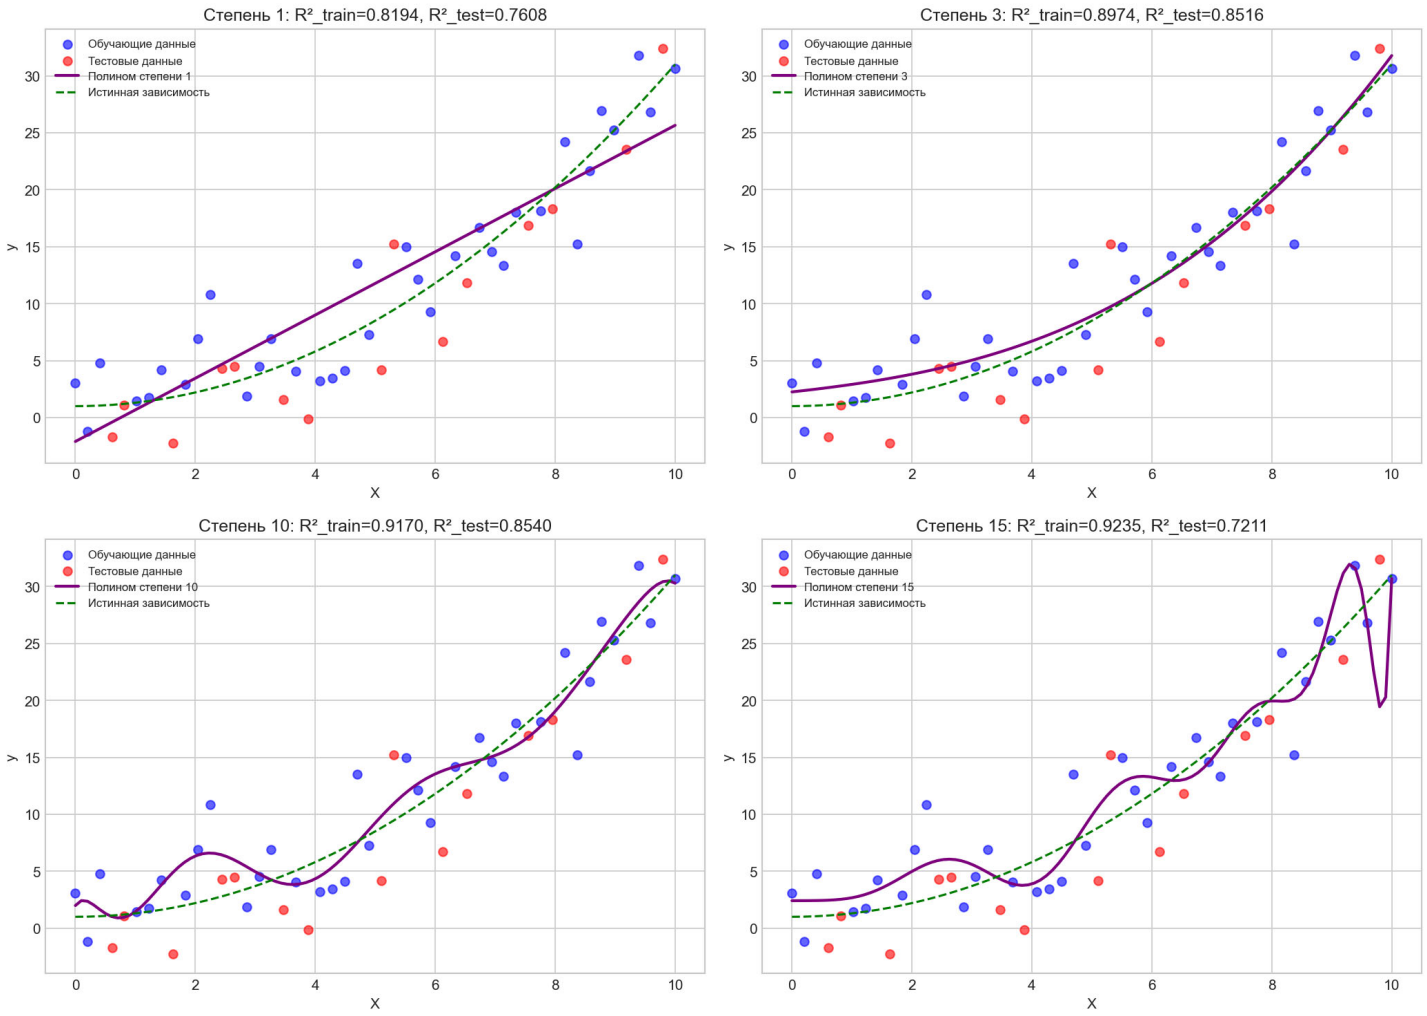

Рис: Сравнение эффектов подбора при разных степенях полинома

- **Степень 1 (Недообучение)**: Линейная модель не может уловить нелинейную зависимость; модель слишком простая
- **Степень 3-10 (Хорошо)**: Модель достаточно хорошо аппроксимирует истинную зависимость
- **Степень 15 (Переобучение)**: Модель слишком сложная, начинает подстраиваться под шум, показывает значительное ухудшение на тестовой выборке

4. Выводы

1. **Анализ датасета Iris**: С помощью визуализации pairplot мы успешно показали распределение признаков и межклассовые соотношения. Признаки лепестка являются ключевыми для разделения видов ирисов.
2. **Классификация логистической регрессией**: Используя логистическую регрессию для бинарной классификации Versicolor и Virginica, мы достигли точности 93.33% на тестовой выборке, что демонстрирует хорошую обобщающую способность модели.
3. **Недообучение и переобучение**:

- Недообучение происходит, когда модель слишком проста для улавливания сложных закономерностей в данных
- Переобучение происходит, когда модель слишком сложная и запоминает шум в обучающих данных
- Оптимальная сложность модели находится в балансе между недообучением и переобучением

4. **Важность регуляризации**: Техники регуляризации могут эффективно предотвращать переобучение и улучшать обобщающую способность модели путём наложения штрафа на сложность модели.

5. Приложение

Сгенерированные визуализационные диаграммы

1. `iris_pairplot.png` — Pairplot датасета Iris
2. `confusion_matrix.png` — Матрица ошибок логистической регрессии
3. `generated_data.png` — Сгенерированные синтетические данные
4. `overfitting_demo.png` — Демонстрация недообучения и переобучения