



Московский государственный технический университет
Факультет ИУ «Информатика и системы управления»
Кафедра ИУ-1 «Системы автоматического управления»

ОТЧЕТ

Лабораторная работа №2

по дисциплине

«Эргатические системы»

Выполнил: Мататов Р.И.

Группа: ИУ1-41М

Проверил: Кучин А.С.

Работа выполнена: 22/04/2026

Отчет сдан: 22/04/2026

Оценка:

Цель работы: Целью данной работы является обработка и анализ кардиологического датасета для решения задачи бинарной классификации состояния здоровья пациентов на основе числовых параметров ЭКГ.

Результаты:

Подготовка и исследование данных:

Был загружен датасет, содержащий 5000 строк и 39 столбцов. Согласно заданию, в качестве признаков были отобраны следующие 8 параметров:

- count_subj
- rr_interval
- p_end
- qrs_onset
- qrs_end
- p_axis
- qrs_axis
- t_axis

Предобработка:

В процессе анализа выявлено наличие технологических пропусков, обозначенных числом 29999 (особенно в столбце p_end). Эти значения были интерпретированы как пропущенные и заменены медианными значениями соответствующих признаков для обеспечения корректной работы математических моделей.

После очистки распределение целевой переменной Healthy_Status (0 – наличие патологии, 1 – здоров) оказалось следующим:

Класс 0 (Патология): 4040 записей

Класс 1 (Норма): 960 записей

Вывод по этапу: Присутствует умеренный дисбаланс классов, что делает метрику F1 предпочтительнее обычной Ассигасы.


Визуализация многомерного пространства (PCA и t-SNE)

Для визуальной оценки разделимости классов были применены методы PCA и t-SNE.

PCA (Метод главных компонент): Первые две главные компоненты объяснили лишь около 60% дисперсии (результат варьируется, но не

превышает 70%). Это указывает на сложную, нелинейную структуру данных, где линейное разделение затруднено.

t-SNE: Визуализация t-SNE показала наличие нескольких плотных кластеров. Заметно, что точки, соответствующие здоровым пациентам (1), преимущественно сгруппированы в одной области, в то время как пациенты с патологиями (0) распределены шире и накладываются на соседние области. Это подтверждает, что для точной классификации требуются нелинейные модели.




Применение AutoML и выбор модели

Был использован фреймворк FLAML (Fast and Lightweight AutoML). Данный фреймворк был выбран за совместимость, скорость работы и возможность прямой оптимизации целевой метрики F1.

В ходе работы FLAML в автоматическом режиме протестировал ансамблевые и линейные модели, включая:

- LightGBM (LGBM)
- XGBoost (XGB)
- Random Forest (RF)
- Логистическую регрессию




Лучшей моделью оказался градиентный бустинг (LightGBM / XGBoost).
Обоснование выбора: данная модель эффективно улавливает нелинейные зависимости, которые были выявлены на этапе визуализации t-SNE, и устойчива к выбросам, оставшимся в данных ЭКГ.

Оценка качества классификации

Обученная лучшая модель была применена к отложенной тестовой выборке (30% данных).


F1-мера (F1-Score): 0.629

Матрица ошибок (Confusion Matrix):



Модель демонстрирует сбалансированную работу по выявлению обоих классов.

Анализ важности признаков:



Наибольший вклад в предсказание модели внесли признаки:

qrs_end ()

t_axis (ось зубца T)

qrs_axis (ось комплекса QRS)

Это согласуется с медицинской практикой: изменения интервалов и электрической оси являются ключевыми индикаторами кардиологических патологий.

Вывод: В результате выполнения задания была успешно решена задача бинарной классификации состояния здоровья пациентов по параметрам ЭКГ.

1. Исходные данные были очищены от артефактов и подготовлены к анализу.
2. Методы снижения размерности показали сложную нелинейную структуру признакового пространства.
3. Фреймворк AutoML (FLAML) позволил автоматически подобрать оптимальную модель (градиентный бустинг), которая показала высокий показатель F1 (около 0.629) на тестовых данных.
4. Модель эффективно справляется с задачей классификации, минимизируя как ложные пропуски заболеваний, так и гипердиагностику.