



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ

ИУ «Информатика и системы управления»

КАФЕДРА

ИУ-1 «Системы автоматического управления»

ОТЧЕТ ПО ЗАДАНИЮ №2

Студент

ИУ1-41М

(Группа)

22/04/2026

(Подпись, дата)

В.С. Водопьянов

(И.О. Фамилия)

Преподаватель

22/04/2026

(Подпись, дата)

А.С. Кучин

(И.О. Фамилия)

2026 г.

Цель работы

Обработать кардиологический дата-сет для решения задачи бинарной классификации по признаку `Healthy_Status`. Ключевые навыки: подготовка данных, применение алгоритмов снижения размерности t-SNE и PCA, сравнение и выбор AutoML-фреймворка, оценка качества классификатора по матрице ошибок и F1-метрике.

Ссылка на датасет: <https://github.com/AI-is-out-there/data2lab>

Описание волн ЭКГ: <https://ecgwaves.com/topic/ecg-normal-p-wave-qrs-complex-st-segment-t-wave-j-point/>

Результаты экспериментов

Задание 1: Подготовка данных и очистка от `sentinel`-значений

Из датасета было загружено 5000 строк. Сформирована обучающая выборка из 9 столбцов: `[Count_subj, rr_interval, p_end, qrs_onset, qrs_end, p_axis, qrs_axis, t_axis, Healthy_Status]`. Обнаружены аномальные значения и отфильтрованы.

Задание 2: PCA-проекция на две главные компоненты

Первые две главные компоненты объясняют суммарно 44.23%. Это говорит о том, что признаки ЭКГ содержат существенную часть независимой информации, и снижение размерности до двух компонент теряет значительную часть сигнала.




Рис. 1. PCA-проекция ЭКГ-признаков на плоскость PC1–PC2

В плоскости PC1–PC2 классы сильно перекрываются: здоровые пациенты (красные) концентрируются в центре облака, но патологические наблюдения (синие) окружают их со всех сторон. Линейная разделимость в этом пространстве слабая — следовательно, линейные классификаторы без преобразования признаков будут работать плохо.

Задание 3: t-SNE-визуализация нелинейной структуры

Для t-SNE использована выборка из 3000 точек (чтобы ускорить расчёт), parameter perplexity = 30. В отличие от PCA, t-SNE хорошо разделяет классы: здоровые наблюдения образуют компактный кластер в левой части карты, а патологические растянуты по большой области — это отражает гетерогенность патологий (аритмии, блокады, инфаркты и т. д.).




Рис. 2. t-SNE-проекция ЭКГ-признаков

Качественный вывод: нелинейные модели (Random Forest, Gradient Boosting) должны работать заметно лучше линейных.

Задание 4: Сравнение моделей (имитация AutoML)

Выборка разбита на обучающую и тестовую в соотношении 70/30 со стратификацией по классу. Для сравнения взяты четыре классификатора: LightGBM, RandomForest, XGBoost и Catboost.

По итогу работы лучшая найденная модель – XGBoost.

Classification report:				
	precision	recall	f1-score	support
Здоров (0)	0.87	0.82	0.85	747
Болен (1)	0.60	0.68	0.63	288
accuracy			0.78	1035
macro avg	0.73	0.75	0.74	1035
weighted avg	0.79	0.78	0.79	1035

Рис. 3. Метрики лучшей модели

Задание 5: Матрица ошибок и финальные метрики

Для лучшей модели построена матрица ошибок на тестовой выборке.




Рис. 4. Матрица ошибок

Вывод

В ходе лабораторной работы освоена типовая схема подготовки данных и выбора модели для бинарной классификации медицинских признаков. На кардиологическом датасете из 5000 строк проведена очистка значений, признаки стандартизованы. Построены проекции PCA и t-SNE: первая показала слабую линейную разделимость, вторая — наличие компактного кластера здоровых пациентов. По итогу были выбраны нелинейные модели, среди которых с помощью AutoML оказалась лучшей XGBoost.