



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ

ИУ «Информатика и системы управления»

КАФЕДРА

ИУ-1 «Системы автоматического управления»

ОТЧЕТ ПО ЗАДАНИЮ №4

Студент

ИУ1-41М

(Группа)

13/05/2026

(Подпись, дата)

В.С. Водопьянов

(И.О. Фамилия)

Преподаватель

13/05/2026

(Подпись, дата)

А.С. Кучин

(И.О. Фамилия)

2026 г.

Цель работы

Обучить свёрточную нейронную сеть, которая по короткому фрагменту электроэнцефалограммы определяет, идёт ли в этот момент эпилептический приступ. Ключевые навыки: формирование обучающей выборки из «сырых» записей ЭЭГ, представление сигнала в виде вейвлет-изображения (скалограммы) и применение свёрточных нейронных сетей для классификации сложных временных рядов.

Ссылка на датасет: <https://physionet.org/content/chbmit/1.0.0/> (подкаталог chb08).

Результаты экспериментов

Задание 1: Формирование обучающей выборки из базы CHB-MIT

Использована база CHB-MIT Scalp EEG Database — записи ЭЭГ пациента chb08 (девочка 3.5 лет с фокальной эпилепсией, 23 канала схемы 10–20, частота дискретизации 256 Гц). Из 21 записи пациента приступы размечены лишь в пяти файлах; чтобы не качать ≈ 40 ГБ полной базы, загружены три файла с приступами (chb08_02, chb08_05, chb08_11) и текстовый файл-аннотация chb08-summary.txt. Из summary программно извлечены интервалы приступов (например, в chb08_02 приступ длится с 2670-й по 2841-ю секунду). Для каждой записи все каналы усреднены в один сигнал, к нему применён низкочастотный фильтр с частотой среза 60 Гц (удаление сетевой наводки и мышечных артефактов). Сигнал нарезан на непересекающиеся окна длиной 4 с (1024 отсчёта). Окно, целиком попавшее внутрь приступа, относится к классу «приступ», окно целиком вне приступа — к классу «норма»; смешанные граничные окна отбрасываются. Поскольку приступы занимают лишь малую долю записи, окон «нормы» получилось на порядок больше, поэтому классы сбалансированы случайной подвыборкой: по 60 окон каждого класса (всего 120 — больше требуемых 50+50).

Задание 2: Построение вейвлет-изображений

Каждое 4-секундное окно переведено в скалограмму с помощью непрерывного вейвлет-преобразования (CWT) с комплексным материнским вейвлетом Морле (cmor1.5-1.0). Взято 80 логарифмически распределённых частот в диапазоне 1–60 Гц, покрывающем ритмы δ , θ , α , β и нижнюю γ . Мощность переведена в децибелы, нормирована по единому для всей выборки диапазону (1-й и 99-й процентиля) и сохранена как цветное PNG-изображение 64×64 пикселя. Изображения разложены по двум папкам: seizure/ (приступ) и normal/ (норма); итого 120 картинок.




Рис. 1. Примеры вейвлет-скалограмм: верхний ряд — окна с приступом, нижний ряд — норма

На скалограммах приступа отчётливо видна повышенная энергия в нижней части спектра (медленные ритмы) и более выраженная вертикальная структура, тогда как у нормы энергия распределена слабее и однороднее. Именно эти частотно-временные сигнатуры и должна уловить свёрточная сеть.

Задание 3: Свёрточная нейронная сеть и её обучение

Построена компактная свёрточная сеть: вход $64 \times 64 \times 3$, нормировка яркости, три свёрточных блока (16, 32 и 64 фильтра 3×3 с пулингом 2×2), затем полносвязные слои на 64 и 32 нейрона с прореживанием (Dropout 0.5) и выходной сигмоидный нейрон. Всего около 288 тыс. обучаемых параметров. Оптимизатор Adam (learning rate $1e-3$), функция потерь — бинарная кросс-энтропия. Выборка разбита на обучающую, валидационную и тестовую части (60/20/20) со стратификацией по классу. Обучение велось до 50 эпох с ранней остановкой по валидационным потерям и восстановлением лучших весов (остановка сработала на 40-й эпохе, лучшая — 34-я).




Рис. 2. Кривые обучения: функция потерь и точность на обучающей и валидационной выборках

Кривые показывают устойчивое снижение потерь и рост точности без признаков грубого переобучения: валидационная точность стабильно держится на уровне 0.85–0.95, а ранняя остановка предотвращает дальнейшее переобучение.

Задание 4: Оценка качества модели

На отложенной тестовой выборке (24 изображения) модель показала точность 0.958: верно классифицированы 23 из 24 окон. Метрики precision/recall/F1-score по обоим классам близки к единице ($F1 \approx 0.96$). Построена матрица ошибок.



Рис. 3. Матрица ошибок на тестовой выборке

Из матрицы ошибок видно, что все окна «нормы» распознаны верно, а среди окон «приступа» допущена лишь одна ошибка (приступ принят за норму). Для медицинской задачи это приемлемый результат при столь небольшой выборке.

Задание 5: Сохранение модели и проверка её работы

Обученная сеть сохранена в файл формата .keras и заново загружена с диска, после чего проверено полное совпадение весов исходной и загруженной модели. Загруженная модель применена к нескольким случайным тестовым изображениям — для каждого выведены истинная метка, прогноз и оценка вероятности приступа.




Рис. 4. Проверка работы загруженной модели на случайных тестовых примерах

Загруженная модель уверенно воспроизводит прогнозы: на показанных примерах предсказанные метки совпадают с истинными, а вероятности близки к 0 для нормы и к 1 для приступа. Это подтверждает работоспособность сохранённой модели «в продакшене».

Вывод

В ходе работы реализован полный пайплайн классификации ЭЭГ на наличие эпилептического приступа. Из базы CHB-MIT (chb08) сформирована сбалансированная выборка из 120 четырёхсекундных окон (по 60 с приступом и без него), каждое окно переведено в вейвлет-скалограмму и сохранено как изображение в соответствующую папку. Обученная свёрточная сеть достигла точности 0.958 на тестовой выборке при F1-score ≈ 0.96 по обоим классам. Модель сохранена в формате .keras и проверена после повторной загрузки. Таким образом, представление ЭЭГ в виде вейвлет-изображений в сочетании со свёрточной сетью позволяет надёжно отличать приступ от фоновой активности даже на небольшой обучающей выборке.