

МГТУ им. Н. Э. Баумана

Задание №5

**Исследование когнитивных характеристик мозга по данным
ЭЭГ**

**Отчет по выполнению задания: wavelet-преобразование EEG-
сигнала и обучение нейронной сети**

Салех Али(2) ИУ1И-41М

Москва 2026 г

1. Цель работы

преобразовать временные EEG-сигналы в частотно-временные изображения с помощью wavelet-преобразования и обучить нейронную сеть для бинарного распознавания когнитивной характеристики мозга: представление движения левого или правого кулака.

2. Исходные данные и описание эксперимента

В работе использованы четыре CSV-файла: тренировочная матрица сигналов, тестовая матрица сигналов, метки тренировочной выборки и метки тестовой выборки. Каждая строка файла с сигналом рассматривается как отдельный EEG-фрагмент длиной 3000 отсчетов.

Описание эксперимента соответствует PhysioNet EEG Motor Movement/Imagery Dataset v1.0.0. В исходном наборе записывались 64-канальные EEG-сигналы с использованием системы BCI2000. Среди экспериментальных задач присутствует воображаемое открывание и закрывание левого или правого кулака. Частота дискретизации исходной базы PhysioNet составляет 160 Гц.

Объект	Количество строк	Количество признаков	Файл
X_train	400	3000	MI-EEG-B9T.csv
y_train	400	1	2class_MI_EEG_train_9.csv
X_test	320	3000	MI-EEG-B9T (1).csv
y_test	320	1	2class_MI_EEG_test_9.csv

Таблица 1 — Структура загруженных файлов

Важное замечание по данным: Тестовая матрица была обрезана до 320 объектов: X_test имел 400 строк, y_test — 320. Файлы MI-EEG-B9T.csv и MI-EEG-B9T (1).csv идентичны; независимая тестовая оценка требует проверки исходных файлов.

3. Первичный анализ датасета

Тренировочная выборка содержит 400 объектов. Распределение классов сбалансировано: класс 0 — 200 объектов, класс 1 — 200 объектов. Тестовые метки также сбалансированы: класс 0 — 160 объектов, класс 1 — 160 объектов.




Рисунок 1 — Пример временного EEG-сигнала




Рисунок 2 — Распределение классов в тренировочной выборке

4. Wavelet-преобразование

Для перехода от одномерного временного сигнала к изображению использовано частотно-временное представление на основе комплексной морле-вейвлет-функции. Для каждого сигнала выполнялись следующие действия: нормировка амплитуды, вычисление коэффициентов wavelet-преобразования для частот от 4 до 40 Гц, логарифмическое масштабирование энергии коэффициентов, приведение изображения к размеру 64×128 и нормировка в диапазон $[0, 1]$.

В результате каждый EEG-фрагмент был представлен как изображение, где горизонтальная ось соответствует времени, вертикальная ось — частоте, а интенсивность пикселя отражает нормированную энергию сигнала.




Рисунок 3 — Пример wavelet-изображения EEG-сигнала

5. Модель нейронной сети

Для классификации использована нейросетевая схема Wavelet → PCA → MLP. Сначала wavelet-изображение разворачивалось в вектор признаков, затем признаки стандартизировались. Для уменьшения размерности применялся PCA с 64 компонентами. После этого выполнялась классификация многослойным перцептроном MLPClassifier с двумя скрытыми слоями размерности 64 и 32 нейрона.

Выбор MLP объясняется малым объемом выборки: для 400 тренировочных объектов полноценная глубокая CNN может переобучаться. При увеличении числа объектов ту же постановку можно расширить до сверточной нейронной сети, которая будет обучаться непосредственно по изображениям 64×128 .

Параметр	Значение
Преобразование	Wavelet / комплексная Morlet-функция
Диапазон частот	4–40 Гц
Размер изображения	64×128
Метод снижения размерности	PCA, 64 компонент
Классификатор	MLPClassifier, слои 64 и 32
Метрики	Accuracy, F1-macro, confusion matrix

Таблица 2 — Параметры вычислительного эксперимента

6. Результаты обучения и тестирования

Для контроля качества тренировочная выборка была разделена на обучающую и валидационную части в соотношении 80/20 с сохранением баланса классов.

Метрика	Значение
Train accuracy	1.0000
Validation accuracy	0.7125
Validation F1-macro	0.7121
Test accuracy	0.4969
Test F1-macro	0.4968

Таблица 3 — Итоговые метрики качества




Рисунок 4 — Динамика функции потерь MLP




Рисунок 5 — Сравнение точности на train, validation и test




Рисунок 6 — Матрица ошибок на тестовой выборке

Матрица ошибок на тестовой выборке имеет вид: $[[77, 83], [78, 82]]$. Поскольку тестовый CSV с сигналами совпадает с тренировочным CSV и имеет больше строк, чем файл тестовых меток, тестовую метрику нельзя считать полностью независимой. Более показательным в данном запуске является качество на валидационной части тренировочной выборки: accuracy = 0.7125, F1-macro = 0.7121.

7. Вывод

В ходе работы была выполнена загрузка EEG-датасета, построены wavelet-изображения временных сигналов, обучена нейронная сеть MLP и рассчитаны метрики качества. Wavelet-преобразование позволило представить временной EEG-сигнал в форме изображения, пригодной для машинного обучения. Полученные результаты подтверждают применимость такого подхода для задачи бинарного распознавания моторного воображения: левый/правый кулак.

При этом для окончательной научной интерпретации необходимо проверить корректность тестовой выборки, так как в предоставленных файлах обнаружено несовпадение числа строк и совпадение train/test сигналов. После исправления исходного тестового файла код в Jupyter Notebook можно запустить без изменения логики обработки.

8. Список источников

PhysioNet. EEG Motor Movement/Imagery Dataset v1.0.0. URL: <https://physionet.org/content/eegmmidb/1.0.0/> (дата обращения: 03.05.2026).

Schalk G., McFarland D. J., Hinterberger T., Birbaumer N., Wolpaw J. R. BCI2000: A General-Purpose Brain-Computer Interface (BCI) System. IEEE Transactions on Biomedical Engineering. 2004. Vol. 51, No. 6. P. 1034–1043.

Goldberger A. et al. PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals. Circulation. 2000. Vol. 101(23). P. e215–e220.