



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ

ИУ «Информатика и системы управления»

КАФЕДРА

ИУ-1 «Системы автоматического управления»

Эргатические Системы

Лабораторная работа №5

Алгоритмы классификации в нейронных сетях.

Студент Канаан Хусейн

Группа ИУ1И-41М

Преподаватель А.С. Кучин

2026 г

1. Цель и постановка задачи

Цель лабораторной работы — исследовать когнитивные характеристики мозга по данным электроэнцефалографии и построить модель классификации моторного воображения. Требовалось загрузить тренировочную и тестовую выборки, проанализировать структуру данных, преобразовать одномерный временной сигнал ЭЭГ в изображение при помощи вейвлет-преобразования и обучить нейронную сеть для определения представления о движении левого или правого кулака.

Задача сформулирована как бинарная классификация. Один объект соответствует одной строке CSV-файла и содержит 3000 отсчетов ЭЭГ. Метка класса принимает значение 0 или 1. Качество модели оценивалось по независимой тестовой выборке с использованием accuracy, precision, recall, F1-score и матрицы ошибок.

2. Исходные данные

В работе использованы четыре файла: MI-EEG-B9T.csv, MI-EEG-B9E.csv, 2class_MI_EEG_train_9.csv и 2class_MI_EEG_test_9.csv. Набор связан с экспериментами EEG Motor Movement/Imagery Dataset, в которых регистрируются ЭЭГ-сигналы при выполнении или воображении двигательных действий. Для выполнения задания данные представлены в удобном табличном формате: строки являются объектами классификации, столбцы — отсчетами сигнала.

Таблица 1 — Размерность и баланс классов

Выборка	Файл	Размер X	Размер y	Баланс классов
Тренировочная	MI-EEG-B9T.csv	400 × 3000	400	0: 200; 1: 200
Тестовая	MI-EEG-B9E.csv	320 × 3000	320	0: 160; 1: 160

Обе выборки сбалансированы, поэтому случайное угадывание должно давать около 50 % accuracy. Визуальный анализ временных сигналов показывает, что классы не имеют очевидного различия только по форме амплитуды. Это делает необходимым переход к частотно-временному представлению.




Рисунок 1 — Примеры исходных ЭЭГ-сигналов для классов 0 и 1

3. Вейвлет-преобразование

Для получения изображения применялось непрерывное вейвлет-преобразование. Этот метод позволяет одновременно учитывать локализацию сигнала по времени и распределение энергии по масштабам. Для нестационарных биомедицинских сигналов такой подход

Нормализация выполнялась по среднему значению и стандартному отклонению тренировочной выборки. Такой порядок исключает перенос информации из тестовой выборки в процесс обучения.




Рисунок 2 — Вейвлет-представление одного ЭЭГ-сигнала

4. Архитектура и обучение CNN

Для классификации использована сверточная нейронная сеть StableWaveletCNN, реализованная на PyTorch. Сверточная архитектура выбрана потому, что после вейвлет-преобразования каждый сигнал представлен как изображение: одна ось соответствует масштабу, другая — времени. Сеть включает три сверточных блока, AdaptiveAvgPool2d и полносвязный классификатор.

Таблица 2 — Основные параметры модели

Компонент	Параметры	Назначение
Conv-блоки	1→8, 8→16, 16→32; ядра 5×5 и 3×3	Выделение локальных частотно-временных признаков
Pooling и Dropout	MaxPool2d, Dropout2d 0,1–0,2	Снижение размерности и регуляризация
Классификатор	Linear 1024→64→2, Dropout 0,4	Получение двух выходных логитов

Обучение выполнялось с функцией потерь CrossEntropyLoss и оптимизатором AdamW. Скорость обучения составляла 0,0003, коэффициент weight decay — 0,001, размер мини-пакета — 32. Для выбора итоговой модели использовалось минимальное значение validation loss, что уменьшает риск выбора переобученной версии сети.

5. Результаты эксперимента

Во время обучения training loss постепенно уменьшался, а validation loss после начального снижения начал колебаться. Это характерно для задач

классификации ЭЭГ, где количество объектов невелико, а сами сигналы шумные и вариативные. Динамика validation accuracy показывает, что модель стабильно превысила уровень случайного угадывания и в отдельные эпохи достигала примерно 0,70–0,75.




Рисунок 3 — Графики функции потерь и ассигасу на валидации

Таблица 3 — Метрики на тестовой выборке

Класс	Precision	Recall	F1-score	Support
0	0,70	0,88	0,78	160
1	0,84	0,62	0,72	160
macro avg	0,77	0,75	0,75	320
weighted avg	0,77	0,75	0,75	320

Итоговая точность на тестовой выборке составила 0,7531, то есть 75,31 %. Значение test loss равно 0,5277. Распределение предсказаний составило 201 объект класса 0 и 119 объектов класса 1, поэтому модель не свелась к тривиальному прогнозированию одного класса.




Рисунок 4 — Матрица ошибок на тестовой выборке

6. Анализ результатов

Согласно матрице ошибок, для класса 0 правильно классифицирован 141 объект из 160, а 19 объектов ошибочно отнесены к классу 1. Для класса 1 правильно классифицировано 100 объектов из 160, а 60 объектов ошибочно отнесены к классу 0. Следовательно, recall для класса 0 заметно выше, чем для класса 1. Это означает, что сеть увереннее распознает первый тип моторного воображения, тогда как второй тип чаще смешивается с первым.

Несмотря на неполный баланс recall между классами, результат является осмысленным для биомедицинской задачи. ЭЭГ имеет низкое отношение сигнал/шум, высокую индивидуальную изменчивость и сложную частотно-временную структуру. При 400 обучающих объектах точность выше 75 % показывает, что вейвлет-изображения действительно содержат признаки, полезные для классификации моторного воображения.

Заключение

В лабораторной работе была реализована полная схема классификации моторного воображения по данным ЭЭГ: загрузка CSV-файлов, проверка размерности и баланса классов, построение вейвлет-изображений, обучение сверточной нейронной сети и анализ тестовых метрик. Итоговая модель

StableWaveletCNN достигла accuracy 75,31 % на независимой тестовой выборке.

Полученные результаты подтверждают, что преобразование временного ЭЭГ-сигнала в частотно-временное изображение и последующая обработка CNN являются рабочим подходом для распознавания когнитивных состояний, связанных с воображением движения левого или правого кулака. Возможные направления улучшения включают подбор диапазона масштабов, увеличение объема данных, а также использование более специализированных EEG-архитектур.