



Московский государственный технический университет
Факультет ИУ «Информатика и системы управления»
Кафедра ИУ-1 «Системы автоматического управления»

ОТЧЕТ

Лабораторная работа №5

по дисциплине

«Эргатические системы»

Выполнил: Мататов Р.И.

Группа: ИУ1-41М

Проверил: Кучин А.С.

Работа выполнена: 19/05/2026

Отчет сдан: 19/05/2026

Оценка:

Цель работы: Исследование когнитивных характеристик мозга на основе данных электроэнцефалографии (ЭЭГ) с применением методов машинного обучения. Основная задача — разработка и обучение нейронной сети для классификации моторного воображения (представление о сжатии левого или правого кулака) на основе частотно-временного анализа ЭЭГ-сигналов с использованием вейвлет-преобразования.

Результаты:

1. Загрузка и подготовка данных

Для выполнения работы использовались данные ЭЭГ, записанные в рамках эксперимента по моторному воображению (Motor Imagery). Данные были загружены из открытого репозитория GitHub. В обучающей выборке содержалось 400 образцов, в тестовой — 320 образцов. Каждый образец представляет собой временной ряд ЭЭГ-сигнала длительностью 3000 отсчётов при частоте дискретизации 160 Гц.

Исходные данные имеют следующие размерности:

Обучающая выборка: (400, 3000)

Тестовая выборка: (320, 3000)

2. Вейвлет-преобразование сигналов

Для извлечения частотно-временных характеристик из сигналов ЭЭГ было применено непрерывное вейвлет-преобразование (CWT) с использованием вейвлета Морле (morl). Преобразование выполнялось для масштабов от 1 до 32, что позволяет охватить основные частотные диапазоны ЭЭГ-ритмов. В результате каждый образец сигнала был преобразован в двумерную скалограмму размером (32, 3000), где одно измерение соответствует масштабу (частоте), а второе — времени.



Рисунок 1 — Пример скалограммы ЭЭГ-сигнала после вейвлет-преобразования

3. Архитектура нейронной сети

Для классификации полученных скалограмм была использована свёрточная нейронная сеть (CNN) со следующей архитектурой:

Входной слой: (1, 32, 3000) — одноканальное изображение скалограммы

Свёрточный блок 1: Conv2d(1→16, kernel=3×3) → BatchNorm → ReLU → MaxPool2d(2×2)

Свёрточный блок 2: Conv2d(16→32, kernel=3×3) → BatchNorm → ReLU → MaxPool2d(2×2)

AdaptiveAvgPool2d(8×8) — адаптивный пулинг для приведения к фиксированному размеру

Классификатор: Linear(2048→128) → ReLU → Dropout(0.5) → Linear(128→2)

Выходной слой содержит 2 нейрона с функцией активации Softmax для бинарной классификации (левый кулак / правый кулак).

4. Обучение модели

Обучение модели проводилось на протяжении 100 эпох с использованием оптимизатора Adam (learning rate = 0.001) и функции потерь CrossEntropyLoss. Размер батча составлял 32 образца. На каждой эпохе оценивались потери и точность как на обучающей, так и на тестовой выборках.




Рисунок 2 — Графики потерь и точности в процессе обучения

На графиках видно, что модель успешно обучается. Отсутствие значительного разрыва между train и test метриками свидетельствует об отсутствии переобучения.

5. Оценка результатов

По завершении обучения модель была протестирована на отложенной тестовой выборке из 320 образцов. Итоговая точность 0.809.




Рисунок 3 — Матрица ошибок классификации

Вывод: Полученные результаты демонстрируют, что методы глубокого обучения в сочетании с частотно-временным анализом сигналов являются перспективным подходом для задач классификации моторного воображения по данным ЭЭГ. Дальнейшее улучшение точности возможно за счёт более тонкой настройки гиперпараметров модели, использования аугментации данных или применения более сложных архитектур нейронных сетей.