



**Московский государственный технический университет
Факультет ИУ «Информатика и системы управления»
Кафедра ИУ-1 «Системы автоматического управления»**

ОТЧЕТ

Эргагические системы

**Классификация сигналов ЭЭГ при визуализации движений на
основе вейвлет-преобразования и нейронных сетей**

Лабораторной работе №.5

Выполнил: Ван Цзюньтао

Группа: ИУ1И-41М

Проверил: Андриков,Д.А.

Цель работы: С помощью вейвлет-преобразования преобразуем временные ряды ЭЭГ, записанные во время воображаемых движений, в частотно-временные изображения, что позволяет получить двумерное частотно-временное представление одномерного сигнала..

Извлечение компактных временных и частотных характеристик из временных и частотных графиков вейв-преобразования позволяет избежать проблемы переобучения высокоразмерных изображений.

Построение нейронной сети многослойного перцептора (MLP) для классификации вейв-характеристик и распознавания воображаемых движений левой и правой рук.

Сравнение эффективности MLP, случайного леса и XGBoost при решении задачи классификации воображаемых движений.

Теоретические основы

1. Непрерывное вейвлет-преобразование (CWT)

Непрерывное вейвлет-преобразование отображает одномерный временной сигнал в двумерную плоскость «время-частота», обеспечивая много разрешающий анализ с помощью вейвлет-базиса Морле с переменным масштабом. CWT обладает высоким частотным разрешением в низкочастотном диапазоне и высоким временным разрешением в высокочастотном диапазоне, что позволяет эффективно улавливать переходные изменения частоты явлений ERD/ERS (событийная десинхронизация/синхронизация), связанных с воображаемым движением, в сигналах ЭЭГ. Карта вейв-масштабов, представляющая собой изображение сигнала во временной и частотной областях, может напрямую вводиться в CNN для распознавания образов.

2. Многослойная нейронная сеть (MLP) и извлечение вейвлет-особенностей

Многослойная нейронная сеть (MLP) — это наиболее классическая архитектура прямого пропускания, состоящая из нескольких полностью связанных слоев, которая реализует аппроксимацию сложных функций с помощью нелинейных активирующих функций (таких как ReLU). Ключевая инновация данного эксперимента заключается в том, что вейвлет-карта масштабов не преобразуется непосредственно в изображение для ввода в CNN (при небольшом количестве образцов CNN не может выучить дискриминационные признаки из 16384-мерных пикселей), а из вейвлет-карт времени-частоты извлекается компактный 68-мерный вектор признаков: проводится усредненное объединение плоскости «время-частота» по 6 полосам частот ЭЭГ ($\theta/\mu_{low}/\mu_{high}/\beta_{low}/\beta_{high}/\gamma$) $\times$ 6 временных интервалов, вычисляются относительные изменения ERD/ERS по отношению к базовой линии

(полосы частот μ и β), а также глобальные статистические показатели для каждой полосы частот (среднее значение, стандартное отклонение). Эти 68-мерные признаки сохраняют информацию о временной и частотной структуре, но размерность уменьшается в 240 раз, что позволяет MLP эффективно обучаться в условиях небольшого объема данных. MLP использует сигмоидный выходной слой для реализации бинарной классификации (воображаемое движение левой/правой руки).

3. Набор данных: PhysioNet EEGMMIDB

База данных PhysioNet EEG Motor Movement/Imagery Database (EEGMMIDB), предоставленная PhysioNet, содержит данные ЭЭГ 109 испытуемых во время выполнения или воображения двигательных задач. Данные хранятся в формате EDF с частотой дискретизации 160 Гц и включают 64 канала электродов (международная система 10-20). Экспериментальные задачи включают: отдых с открытыми/закрытыми глазами, выполнение движений левой/правой рукой, воображение движений левой/правой рукой и т. д. В данном эксперименте используются данные о воображении движений испытуемого В9 (воображение сжатия кулаков левой и правой руки).

Практическая часть

Описание набора данных

1. Источник данных

В данном эксперименте использовались данные ЭЭГ, полученные при визуализации движения у испытуемого В9 из базы данных PhysioNet EEGMMIDB. Данные были преобразованы в формат CSV, причем каждая строка представляет собой временной ряд ЭЭГ одного испытания по визуализации движения (3000 точек временной дискретизации, примерно 18,75 секунд). Данные были помечены в соответствии с поведением испытуемого во время эксперимента и разделены на две категории: воображаемое движение левой руки (категория 0) или воображаемое движение правой руки (категория 1). Набор данных был заранее разделен на обучающую и тестовую выборки.

2. Статистика набора данных

Обучающая выборка содержит 400 ЭЭГ-экспериментов, тестовая выборка — 320 ЭЭГ-экспериментов. Каждый эксперимент содержит 3000 точек временной дискретизации (частота дискретизации 160 Гц, примерно 18,75 секунд). Для каждого временного ряда ЭЭГ с помощью вейв-преобразования Морле (CWT) в диапазоне частот 4–40 Гц (224 масштаба) вычисляется плотность спектра мощности (в дБ). Затем из временных спектров CWT извлекается компактный 68-мерный вектор признаков: средняя мощность по 6 полосам частот ЭЭГ $\times$ 6

временных интервалов (36 измерений), признаки изменения ERD/ERS в полосах частот му/бета (20 измерений), а также статистические показатели среднего значения и стандартного отклонения для каждой полосы частот (12 измерений). Для преодоления переобучения на небольшой выборке обучающий набор подвергается 5-кратному усилению данных на уровне сигнала (гауссовый шум + временное смещение + масштабирование амплитуды), в результате чего 400 обучающих экспериментов расширяются до 2000. Одновременно сохраняются 3 образца вейвовых изображений воображаемого движения левой руки и 3 образца — воображаемого движения правой руки для визуализации.

Таблица 1. Статистика набора экспериментальных данных

Категория	Обучающая выборка	Тестовая выборка	Продолжительность сигнала	Частота дискретизации
Визуализация движений левой руки (Левый кулак)	146	1000 (после расширения)	18.75 с	160 Гц
Визуализация движений правой руки (Правый кулак)	150	1000 (после расширения)	18.75 с	160 Гц
Всего	196	2000	/	/

3. Примеры вейвлет-изограмм

На рисунках 1 и 2 представлены типичные диаграммы векторов масштаба вейвлетов для воображаемых движений левой и правой руки соответственно. Явления ERD/ERS, связанные с воображаемыми движениями, в основном проявляются в диапазонах му-ритма (8–13 Гц) и бета-ритма (13–30 Гц). Во время воображаемых движений рук в этих диапазонах наблюдается заметное снижение мощности (ERD) в контралатеральной сенсомоторной коре, а после завершения движения — повышение мощности (ERS).




Рис. 1. Пример графического представления вейвлет-масштаба ЭЭГ при визуализации движений левой руки




Рис. 2. Пример графического отображения вейвлет-масштаба ЭЭГ при визуализации движений правой руки

Моделирование и реализация эксперимента

1. Загрузка и предварительная обработка данных

Для загрузки обучающих и тестовых данных ЭЭГ в формате CSV используется библиотека Pandas. Обучающий набор содержит 400 ЭЭГ-записей (MI-EEG-B9T.csv), а тестовый набор — 320 ЭЭГ-записей (MI-EEG-B9E.csv). Каждый эксперимент представляет собой 3000 точек временной выборки с плавающей запятой, частота дискретизации составляет 160 Гц (стандартная частота дискретизации PhysioNet EEGMMIDB). Соответствующие метки (0 = воображаемое движение левой руки, 1 = воображаемое движение правой руки) загружаются из отдельного файла CSV с метками. Все данные прошли предварительную обработку и представлены в виде одноканальных временных рядов.

2. Извлечение вейвовых характеристик

Для каждого временного ряда ЭЭГ с помощью вейва Морле (Morlet) вычисляется непрерывное вейвовое преобразование (CWT) в диапазоне частот 4–40 Гц (224 частотных масштаба), в результате чего получается матрица плотности спектра мощности в децибелах (224×3000). Затем из временного спектра CWT извлекается компактный 68-мерный вектор характеристик: (1) Особенности временной и частотной сетки: 6 полос частот ЭЭГ (theta 4–8 Гц / μ_{low} 8–10 Гц / μ_{high} 10–13 Гц / β_{low} 13–20 Гц / β_{high} 20–30 Гц / gamma 30–40 Гц) × 6 одинаковых временных интервалов (каждый около 3,1 секунды) были усреднены и объединены, что дало 36-мерные особенности; (2) Особенности ERD/ERS: изменение мощности четырех полос частот (μ_{low} , μ_{high} , β_{low} , β_{high}) в пяти последующих временных интервалах по отношению к базовому периоду первого интервала, что дает 20-мерные особенности; (3) Глобальные статистические показатели: среднее значение и стандартное отклонение шести полос частот, что дает 12-мерные особенности. Вектор

признаков после нормализации с помощью StandardScaler используется для обучения MLP. Одновременно сохраняется небольшое количество примеров вейвлет-изображений для визуализации отчета.

3. Структура и обучение модели MLP

Для обработки 68-мерных вейвлет-особенностей во времени и частоте используется 3-слойная полностью соединенная архитектура MLP: Dense(128)→BatchNorm→Dropout(0.3) → Dense(64)→BatchNorm→Dropout(0.2) → Dense(32)→BatchNorm→Dropout(0.2) → Dense(1, sigmoid). Общее количество параметров составляет всего 20 тыс. (что намного меньше, чем у CNN — 25 тыс. и более). Оптимизатор Adam с начальной скоростью обучения $1e-3$, адаптивное затухание ReduceLROnPlateau (factor=0,5, patience=12), функция потерь Binary Cross-Entropy. Обучение проводилось в течение 150 эпох (раннее остановка patience=30), размер партии — 32. Набор данных для обучения был увеличен в 5 раз до 2000 записей с помощью усиления на уровне сигнала (гауссовый шум std=0,05, временной сдвиг ± 150 точек отсчета, масштабирование амплитуды 0.92–1.08). По сравнению с CNN, напрямую обрабатывающей изображения с 16 384 измерениями, эффективность обучения MLP на компактных 68-мерных признаках значительно повысилась, а риск переобучения значительно снизился.

4. Инженерия признаков + базовый алгоритм «Случайный лес»

Для построения надежного базового результата и проверки различимости данных был реализован метод машинного обучения на основе ручных признаков. Для каждого экспериментального ЭЭГ-записи были извлечены 14-мерные признаки мощности в частотных полосах: мощность в полосах mu (8–13 Гц), beta (13–30 Гц), theta (4–8 Гц) и gamma (30–45 Гц) по всему отрезку (в логарифмическом масштабе $\log_{10}$); мощность в диапазонах му и бета для 3 временных отрезков (по 6.25 секунд каждый); изменение мощности между отрезками (режимы ERD/ERS). После нормализации признаков с помощью StandardScaler были обучены классификаторы «Случайный лес» (500 деревьев, max_depth оптимизировано с помощью поиска по сетке в диапазоне 3–14) и XGBoost (300 деревьев, max_depth = 3).

Результаты эксперимента и анализ

1. График во временной области многоканальной ЭЭГ

На рисунке 3 представлены кривые изменения потерь при обучении и точности модели MLP на основе вейвовых временно-частотных признаков. Благодаря компактному 68-мерному представлению признаков и расширению данных на уровне сигнала (5-кратное увеличение объема) обучение MLP стабильно сходилось, а точность на валидации неуклонно росла до уровня свыше 77 % без проявления переобучения.




Рис. 3. Кривые потерь и точности в процессе обучения MLP

На рис. 4 представлена матрица путаницы MLP на тестовом наборе, демонстрирующая результаты классификации модели по воображаемым движениям левой и правой руки. Диагональные элементы матрицы путаницы преобладают, а показатели воспроизводимости для обеих категорий сбалансированы (83 % для левой руки и 71 % для правой), что свидетельствует об эффективности обучения MLP на основе временных и частотных вейвовых характеристик.




Рис. 4. Матрица путаницы тестового набора MLP

В таблице 2 представлено сравнение количественных характеристик всех моделей. MLP (волновые временные и частотные признаки) продемонстрировала наилучшие результаты с точностью 77.19 % и показателем F1 0.7575, что подтвердило эффективность стратегии, заключающейся в извлечении компактных признаков из CWT и последующей классификации с помощью MLP. Следом за нейкой идет модель случайного леса (частотно-полосные мощностные признаки FFT) с точностью 75.31%, а XGBoost — с точностью 71.25%.

Таблица 2. Сравнение эффективности моделей

Категория	Точность	Показатель F1	Точность	Показатель F1
MLP	77.19%		0.7575	
Случайный лес	75.31%		0.7427	




Рис. 5. Матрица путаницы для тестового набора модели «Случайный лес»

Выводы

В ходе данного эксперимента удалось успешно извлечь вейвовые временно-частотные характеристики из данных о мысленных движениях испытуемого В9 из базы данных PhysioNet EEGMMIDB и сформировать набор данных, включающий 2000 обучающих и 320 тестовых образцов (каждый с 68-мерными характеристиками).

С помощью непрерывного вейвлет-преобразования Морле (Morlet) временные ряды ЭЭГ были преобразованы в временно-частотное представление, из которого были извлечены компактные 68-мерные векторы признаков, эффективно сохранившие дискриминационную информацию, связанную с воображаемыми движениями.

Нейронная сеть MLP (20К параметров) достигла на векторе вейвлет-описания точности тестирования 77.19% и F1-показателя 0.7575, что подтвердило ключевую роль снижения размерности признаков для глубокого обучения на небольших наборах данных ЭЭГ.

Случайный лес (Random Forest) достиг точности 75.31% при использовании только 14-мерных характеристик мощности полос FFT, что указывает на различимость одноканальных данных ЭЭГ как таковых — ключ заключается в том, как сжать высокомерное временно-частотное представление в компактные характеристики, которые может обучаться модель.